## Tarea 1 - Raimundo Herrera

Para esta tarea se pretende diferenciar caracteres de 's' y 'c' de distintas fuentes por medio de reconocimiento de patrones simples, presentes en los mismos caracteres. Esta actividad sirve para explorar las técnicas de reconocimiento de patrones, y las fases que este procedimiento implica. En primer lugar explorar la creación de *datasets* propios, que son los utilizados para entrenar nuestros algoritmos. Luego la extracción de características de una imagen, para después decidir cuales son relevantes y cuales no, de modo de finalmente poder generar un algoritmo robusto para dicha tarea.

Para la solución propuesta, en primer lugar se creó un dataset variado a partir de imágenes simples. Se obtuvo una imagen para cada carácter en cada una de las fuentes especificadas, en sus variaciones *regular* y *bold*. Con estas imágenes (12), dado que las letras no varían su forma variando el tamaño, se procedió a aumentar el dataset. Para esto, se utilizaron diversas funciones que agregaron *padding* en cada imagen, en cada una de las 4 direcciones posibles, y modificaron los tamaños. Se incluyó en el *.zip* entregado el Python Notebook utilizado para ello, pero no las imágenes, que deberían ubicarse bajo */dataset*.

En segundo lugar, se procedió a extraer las características de cada imagen, para lo cual se utilizó el apoyo de librerías como *numpy* y *matplotlib*. Se experimentó con extraer el centro de masa de las imágenes; obtener las esquinas reales de cada letra, para así ser invariante al *padding*; y también obtener la proporción de cada imagen que corresponde a letra y no a fondo. Para evitar casos bordes relacionados con el centro de masa, se realizó una expansión del mismo, donde no solo se obtuvo el centro, sino que el cuadrado que rodea, esto es, los 9 pixeles centrales. Cada una de las cosas descritas anteriormente con funciones autoexplicativas y unitarias en el código, como la función *get surrounding region*.

Lo anterior basado en la hipótesis de que las letras 'c' en su centro de masa apuntan a fondo, esto es, y que las letras 's' apuntan a contenido, o valores 1. Además para ciertos ejemplos se apreció que la proporcion de masa era mayor para las 's' que para las 'c'. Para que la hipótesis fuera probada o refutada de modo robusto, se procesaron las imágenes y se realizó una simple regresión lineal entre los valores señalados anteriormente: los valores de los puntos del centro y la proporción descrita. Sin embargo, resultó ser, tras extraer las características del extenso set de datos, que la única significativa de las extraídas era el valor del centro de masa y sus alrededores. Esto dado los valores de los parámetros de la regresión, que dieron nula relevancia a la proporción e igual relevancia a cada uno de los puntos.

Como resultado se dejó la función pedida que realiza un producto punto entre los parámetros obtenidos y la realización del procesamiento de la imagen, que la transforma en un vector, por medio de la función *image to vector*.

Este trabajo, por el tipo de características que se emplearon es muy poco probable que sirva para otras fuentes donde por ejemplo la 's' no sea tan simétrica verticalmente, por lo que hay un sesgo alto en ese respecto. Es importante señalar que muchas veces no es necesario realizar algoritmos muy complejos para tareas simples, dado que con estas herramientas se obtienen desempeños suficientes, como fue este caso. La extracción de características se puede complejizar cuanto uno quiera pero a veces las más simples prevalecen y bastan.